

Proyecto Final — Ingeniería de Datos

DataCommerce GT: Plataforma de Datos Integrada

Integrantes:

- Daniella Marissa Navarro Araniva
- Diego Alejandro Escobar Barahona

Repositorio: https://github.com/bapatata688/proyecto_final.git

Este notebook documenta el proceso técnico realizado en cada día del proyecto (arquitectura, extracción, calidad, modelado, carga y análisis).

Día 1 — Comprensión del negocio y arquitectura

1. El problema de negocio

DataCommerce GT vende productos tecnológicos a través de 4 canales: tiendas físicas, comercio electrónico, ventas corporativas y WhatsApp.

Con el crecimiento de la empresa, la información quedó dispersa en distintos sistemas, lo que provoca que la gerencia no tenga reportes confiables ni oportunos, y que cada departamento genere resultados que no coinciden entre sí.

Solución propuesta: construir una plataforma de datos que integre todas las fuentes en un único Data Warehouse, de manera que exista una sola fuente de verdad para generar los indicadores que la gerencia necesita.


2. Revisión de archivos e identificación de problemas

Se hizo una exploración inicial de cada fuente (filas, columnas, tipos de dato) para detectar de antemano:

- Columnas con valores nulos o faltantes.
- Registros duplicados.

- Formatos inconsistentes entre fuentes (fechas, nombres, categorías, IDs).
- Reglas de limpieza necesarias, para no limpiar a ciegas en el Día 2.

3. Arquitectura de la solución



Stack tecnológico: Python + Pandas (ETL), BigQuery (Data Warehouse), SQL (consultas analíticas), HTML/Chart.js (dashboard).

Por qué esta arquitectura:

- Se separa staging de transformación para no perder los datos crudos originales.
- El pipeline se diseña para ser reproducible: debe poder ejecutarse de nuevo sin intervención manual.
- El modelo dimensional facilita las consultas analíticas y el cálculo de KPIs para gerencia.

4. Modelo relacional preliminar

Entidades identificadas: Cliente, Producto, Venta, Inventario, Tienda/Canal, Campaña.

Relaciones esperadas:

- Un Cliente puede tener muchas Ventas (1:N)
- Un Producto puede aparecer en muchas Ventas (1:N)
- Un Producto tiene inventario en varias Tiendas (N:M, vía Inventario)

- Una Campaña puede influir en varias Ventas

5. Plan del ETL

Extracción por fuente: CSV → `pandas.read_csv()` · Excel → `pandas.read_excel()` · JSON → `pandas.read_json()` · SQLite → `sqlite3` / `pandas.read_sql()` · API REST → `requests.get()` .

Transformaciones esperadas: eliminar duplicados por clave primaria, normalizar fechas a `YYYY-MM-DD` , estandarizar nombres/categorías, definir regla para nulos, unificar IDs entre fuentes.

Carga: primero a staging (datos crudos), luego transformación y carga al modelo dimensional.

Día 2 — Extracción, Calidad y Limpieza

Qué se hizo

Se trabajó directamente sobre los 5 archivos entregados por el instructor (`ventas.csv` , `productos.xlsx` , `clientes.json` , `inventario.db` , `api_marketing_response.json`). `inventario.db` resultó tener **2 tablas** (`inventario_actual` y `movimientos_inventario`), así que el pipeline extrae y limpia **6 tablas** en total.

Estructura de archivos

```
dia_2/
├── config.py                # rutas, variables de entorno, logging
├── extract.py               # 6 funciones de extracción (una por
tabla)
├── quality.py               # perfilado de calidad + integridad
referencial
├── clean.py                 # 6 funciones de limpieza (una por
tabla)
├── ejecutar_extraccion.py
├── ejecutar_perfilado.py
├── ejecutar_limpieza.py
├── data/
│   ├── raw/                # archivos originales entregados por el
instructor
│   ├── interim/            # extraído tal cual, sin limpiar (parquet)
│   └── processed/          # limpio y estandarizado (parquet), listo
```

```
para día 3
└─ reports/
   └─ hallazgos_calidad.md
```

Las 6 tablas y su fuente real

Tabla	Fuente	Origen
ventas	CSV	data/raw/ventas.csv
productos	Excel	data/raw/productos.xlsx
clientes	JSON	data/raw/clientes.json
inventario_actual	SQLite (inventario_actual)	data/raw/inventario.db
movimientos_inventario	SQLite (movimientos_inventario)	data/raw/inventario.db
campanas	API REST (mock si no hay URL)	data/raw/api_marketing_response.js

Nota sobre volumen: los archivos entregados tienen solo encabezados y unas pocas filas de ejemplo. Ningún script asume un número fijo de filas: funcionarán igual con el volumen completo, siempre que se mantengan los mismos nombres de columna.

Cómo se corre el pipeline

```
python ejecutar_extraccion.py      # lee data/raw/          ->
data/interim/*.parquet
python ejecutar_perfilado.py        # perfila data/interim/ ->
reports/hallazgos_calidad.md
python ejecutar_limpieza.py         # limpia data/interim/  ->
data/processed/*.parquet
```

Hallazgos de calidad (proceso, no resultado de negocio)

- **ventas.fecha_venta mezcla 3 formatos** en la misma columna: 2026-07-01 (AAAA-MM-DD), 01/07/2026 (DD/MM/AAAA) y 2026/07/02 (AAAA/MM/DD).
- **clientes.municipio llega como string vacío ("")**, no nulo, para un registro. Un perfilador de nulos estándar no lo detecta porque "" no es NaN.
- **Integridad referencial:** cliente_id 504 aparece en una venta pero no existe en clientes.json — huérfano detectado automáticamente.
- Por observación directa: producto_id 2004 aparece en productos y en una venta, pero no tiene registro en inventario_actual — pendiente de confirmar con el instructor cuando llegue el volumen completo.

Decisión técnica destacada: parseo de fechas mixtas

`pd.to_datetime(..., format="mixed", dayfirst=True)` parece la solución obvia, pero al probarla contra estos datos reales **produce fechas incorrectas**: además de resolver la ambigüedad de `01/07/2026`, también invierte mes y día en fechas año-primero como `2026-07-01`.

La solución en `clean.py` detecta el formato por la posición del año (nunca ambigua, siempre 4 dígitos):

- Año primero (`AAAA-MM-DD` o `AAAA/MM/DD`) → se parsea directo, sin asumir día primero.
- Año al final (`DD/MM/AAAA`) → sí es ambiguo, se asume día primero (convención de Guatemala).

Reglas de limpieza aplicadas y su justificación

Tabla	Regla	Justificación
ventas	Elimina duplicados por <code>venta_id</code>	Un id de venta no puede repetirse
ventas	Normaliza <code>fecha_venta</code> (3 formatos mezclados)	Ver decisión técnica arriba
ventas	<code>cantidad/descuento</code> negativos → valor absoluto	No existen ventas ni descuentos negativos
ventas	<code>total_venta</code> recalculado	No arrastrar errores de captura del archivo original
productos	Elimina duplicados por <code>producto_id</code>	Un producto no puede repetirse en el catálogo
productos	Recorta espacios extra en texto	Error común de captura manual
productos	<code>categoría/subcategoría</code> nulas → "Sin Categoría"	No perder el producto en reportes agrupados
productos	<code>precio_lista</code> no convertible → se descarta la fila	No se puede vender un producto sin precio
clientes	Elimina duplicados por <code>cliente_id</code>	Un cliente no puede repetirse
clientes	<code>municipio</code> "" → nulo	String vacío no es un municipio válido
clientes	<code>fecha_registro</code> normalizada	Consistencia con el resto de fechas
inventario_actual	Elimina duplicados por (<code>producto_id</code> , <code>bodega</code>)	Una bodega no puede tener 2 registros del mismo producto
inventario_actual	existencia negativa → 0	El stock físico nunca es negativo
movimientos_inventario	Elimina duplicados por <code>id</code>	Es la llave primaria del movimiento

Tabla	Regla	Justificación
movimientos_inventario	cantidad negativa → valor absoluto	La dirección la indica <code>tipo</code> ; cantidad es la magnitud
campañas	Elimina duplicados por <code>campaña_id</code>	Una campaña no puede repetirse
campañas	métricas negativas → 0	Son conteos o gasto, nunca negativos

Chequeo automático (self-check)

`ejecutar_limpieza.py` valida, después de limpiar cada tabla, que sus propias reglas se cumplieron (sin duplicados por llave, sin negativos donde no debería haberlos). Si algo se rompe, el script falla con un `AssertionError` explícito en vez de guardar datos incorrectos silenciosamente.

```
(.venv) PS C:\Users\danie\Desktop\business_intelligence\dia_2> python ejecutar_extraccion.py
17:24:25 [INFO] extract: Ventas extraídas: 255000 filas, 11 columnas
17:24:26 [INFO] __main__: ventas: 255000 filas -> ventas.parquet
17:24:26 [INFO] extract: Productos extraídos: 4100 filas, 8 columnas
17:24:26 [INFO] __main__: productos: 4100 filas -> productos.parquet
17:24:27 [INFO] extract: Clientes extraídos: 30600 filas, 8 columnas
17:24:27 [INFO] __main__: clientes: 30600 filas -> clientes.parquet
17:24:27 [INFO] extract: Inventario actual extraído: 4000 filas, 3 columnas
17:24:27 [INFO] __main__: inventario_actual: 4000 filas -> inventario_actual.parquet
17:24:27 [INFO] extract: Movimientos de inventario extraídos: 180000 filas, 5 columnas
17:24:27 [INFO] __main__: movimientos_inventario: 180000 filas -> movimientos_inventario.parquet
17:24:27 [INFO] extract: API_CAMPANAS_URL no configurada; usando mock local
17:24:28 [INFO] extract: Campañas extraídas: 81000 filas, 8 columnas
17:24:28 [INFO] __main__: campanas: 81000 filas -> campanas.parquet

(.venv) PS C:\Users\danie\Desktop\business_intelligence\dia_2> python ejecutar_perfilado.py
Reporte generado en C:\Users\danie\Desktop\business_intelligence\dia_2\reports\hallazgos_calidad.md

(.venv) PS C:\Users\danie\Desktop\business_intelligence\dia_2> python ejecutar_limpieza.py
19:46:14 [WARNING] clean: canal_venta: 1 valor(es) no reconocido(s), marcados como 'Sin Clasificar': ['W']
19:46:15 [WARNING] clean: metodo_pago: 1 valor(es) no reconocido(s), marcados como 'Sin Clasificar': ['T']
19:46:15 [WARNING] clean: limpiar_ventas: 1498 fila(s) descartada(s) por cantidad/precio_unitario no numérico
ventas: 255000 filas crudas -> 248502 filas limpias -> ventas.parquet
19:46:16 [WARNING] clean: 23 producto(s) descartado(s) por precio_lista inválido
productos: 4100 filas crudas -> 4077 filas limpias -> productos.parquet
clientes: 30600 filas crudas -> 30600 filas limpias -> clientes.parquet
inventario_actual: 4000 filas crudas -> 4000 filas limpias -> inventario_actual.parquet
19:46:20 [WARNING] clean: 1552 movimiento(s) descartado(s) por cantidad no numérica
movimientos_inventario: 180000 filas crudas -> 178448 filas limpias -> movimientos_inventario.parquet
campanas: 81000 filas crudas -> 80000 filas limpias -> campanas.parquet
```

Día 3 — Modelado Dimensional y Carga al Data Warehouse

Objetivo del día

Tomar los datos limpios del Día 2, diseñar el modelo dimensional (esquema estrella) y cargarlo al Data Warehouse en BigQuery (`dw_datacommerce`).

Qué se hizo

1. **Diseño del modelo estrella:** 7 tablas de dimensión y 4 tablas de hechos.
2. **Construcción de las tablas (`modelado.py`):** lee los Parquet limpios del Día 2, genera llaves sustitutas (surrogate keys) donde no existía un ID de origen (canal, método de pago, plataforma, bodega), arma las dimensiones y las tablas de hechos.
3. **Carga a BigQuery (`cargar_bigquery.py`):** sube cada tabla al dataset `dw_datacommerce` , reemplazando el contenido en cada corrida (`WRITE_TRUNCATE`) para que el pipeline sea reproducible.
4. **Orquestador (`ejecutar_dia3.py`):** corre los dos pasos anteriores con un solo comando.

Estructura de archivos

Archivo	Función
<code>config.py</code>	Configuración central: PROJECT_ID, dataset, rutas y clave de credenciales
<code>esquema_dw.sql</code>	DDL de las 11 tablas del modelo estrella
<code>modelado.py</code>	Construye dimensiones y hechos a partir de los datos limpios del Día 2
<code>cargar_bigquery.py</code>	Sube las tablas generadas a BigQuery
<code>ejecutar_dia3.py</code>	Orquestador
<code>diagrama_modelo_estrella.svg</code>	Diagrama visual del modelo estrella
<code>diccionario_datos.md</code>	Diccionario de datos: cada tabla, columna, tipo y descripción

Cómo se corre

```
pip install google-cloud-bigquery pandas pyarrow --break-system-packages
```

```
# 1. Crear las tablas en BigQuery con el esquema correcto (una sola vez):  
#   pegar esquema_dw.sql en BigQuery -> "Consulta en SQL"  
# 2. Colocar la clave de la cuenta de servicio como  
#   credenciales_bigquery.json  
# 3. Correr el pipeline completo:  
python ejecutar_dia3.py
```

Decisiones técnicas

- **Cliente huérfano:** la venta con `cliente_id 504` no tenía coincidencia en la tabla de clientes de origen. En vez de descartar la venta, se creó el registro `cliente_key = -1` ("Cliente desconocido") en `dim_cliente`, para conservar el ingreso registrado sin romper el JOIN.
- **dim_sucursal genérica:** no se recibió un catálogo real de sucursales (nombres, direcciones); la dimensión se construyó solo con el `sucursal_id` disponible en las ventas, con nombres genéricos ("Sucursal 1/2/3"). Pendiente de enriquecer si aparece la fuente real.
- **Llaves sustitutas para catálogos pequeños:** canal de venta, método de pago, plataforma y bodega llegaban como texto libre dentro de las tablas de hechos; se generaron dimensiones tipo catálogo con llave autogenerada, evitando texto repetido en los hechos.


Resultado


11 tablas cargadas en `dw_datacommerce`: `dim_producto`, `dim_cliente`, `dim_sucursal`, `dim_canal`, `dim_metodo_pago`, `dim_plataforma`, `dim_bodega`, `fact_ventas`, `fact_movimiento_inventario`, `fact_inventario_existencia`, `fact_marketing`.


```
(.venv) PS C:\Users\danie\Desktop\business_intelligence\dia_3> python ejecutar_dia3.py
=== PASO 1: Modelado dimensional ===
dim_producto: 4077 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_producto.parquet
dim_cliente: 30601 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_cliente.parquet
dim_sucursal: 20 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_sucursal.parquet
dim_canal: 4 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_canal.parquet
dim_metodo_pago: 4 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_metodo_pago.parquet
dim_plataforma: 2 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_plataforma.parquet
dim_bodega: 5 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\dim_bodega.parquet
fact_ventas: 248502 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\fact_ventas.parquet
fact_movimiento_inventario: 178448 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\fact_movimiento_inventario.parquet
fact_inventario_existencia: 4000 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\fact_inventario_existencia.parquet
fact_marketing: 80000 filas -> C:\Users\danie\Desktop\business_intelligence\dia_3\data\dw\fact_marketing.parquet

=== PASO 2: Carga a BigQuery ===
[OK] dim_producto: 4077 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_producto
[OK] dim_cliente: 30601 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_cliente
[OK] dim_sucursal: 20 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_sucursal
[OK] dim_canal: 4 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_canal
[OK] dim_metodo_pago: 4 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_metodo_pago
[OK] dim_plataforma: 2 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_plataforma
[OK] dim_bodega: 5 filas cargadas en proyecto-final-501300.dw_datacommerce.dim_bodega
[OK] fact_ventas: 248502 filas cargadas en proyecto-final-501300.dw_datacommerce.fact_ventas
[OK] fact_movimiento_inventario: 178448 filas cargadas en proyecto-final-501300.dw_datacommerce.fact_movimiento_inventario
[OK] fact_inventario_existencia: 4000 filas cargadas en proyecto-final-501300.dw_datacommerce.fact_inventario_existencia
[OK] fact_marketing: 80000 filas cargadas en proyecto-final-501300.dw_datacommerce.fact_marketing

Día 3 completado: modelo dimensional generado y cargado al DW.
```





Día 4 — Consultas SQL, KPIs con Pandas y Gráficos

Objetivo del día

Consultar el Data Warehouse construido en el Día 3, calcular indicadores de negocio (KPIs) con Pandas, validarlos y generar los gráficos de apoyo al dashboard.

Qué se hizo

1. **Consultas SQL analíticas (consultas_sql.sql)**: 8 consultas directas sobre las tablas de BigQuery del Día 3.
2. **Cálculo de KPIs con Pandas (kpis.py + calcular_kpis.py)**: se trae cada tabla desde BigQuery a un DataFrame y se calculan los indicadores con Pandas, como pide el objetivo del curso. Los resultados se guardan como CSV en data/kpis/ , más un kpis_resumen.json consolidado que usa el dashboard del Día 5.
3. **Gráficos (graficos.py)**: a partir de esos CSV, se generan 6 gráficos PNG en graficos/ .
4. **Orquestador (ejecutar_dia4.py)**: corre el cálculo de KPIs y la generación de gráficos con un solo comando.

Estructura de archivos

Archivo	Función
config.py	Configuración central (reutiliza la clave del Día 3)
consultas_sql.sql	8 consultas SQL analíticas

Archivo	Función
<code>kpis.py</code>	Funciones puras de cálculo de KPIs (reciben DataFrames, se pueden probar sin BigQuery)
<code>calcular_kpis.py</code>	Trae las tablas desde BigQuery, calcula cada KPI y exporta CSV + <code>kpis_resumen.json</code>
<code>graficos.py</code>	Lee los CSV y genera los gráficos PNG
<code>ejecutar_dia4.py</code>	Orquestador

KPIs calculados

1. Ventas totales y ticket promedio por canal de venta
2. Top productos por unidades y monto vendido
3. Ventas totales por sucursal
4. Método de pago más usado
5. Top clientes por monto de compra
6. Existencia actual de inventario por producto y bodega
7. Desempeño de campañas de marketing por plataforma: CTR, costo por lead, tasa de conversión
8. Movimientos de inventario por tipo (entradas vs. salidas)

Cómo se corre

```
pip install google-cloud-bigquery pandas pyarrow matplotlib --break-system-packages
python ejecutar_dia4.py
```

Validación de resultados


Cada KPI calculado con Pandas corresponde a una de las consultas SQL de `consultas_sql.sql` ; se validó corriendo la consulta en BigQuery y comparando el resultado contra el CSV generado en `data/kpis/` , sobre los mismos datos de muestra.

```
(.venv) PS C:\Users\danie\Desktop\business_intelligence\dia_4> python ejecutar_dia4.py
=== PASO 1: Cálculo de KPIs ===
Descargando tablas desde BigQuery...
ventas_por_canal: 4 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\ventas_por_canal.csv
top_productos: 4039 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\top_productos.csv
ventas_por_sucursal: 20 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\ventas_por_sucursal.csv
metodo_pago_mas_usado: 4 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\metodo_pago_mas_usado.csv
top_clientes: 3916 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\top_clientes.csv
existencia_inventario: 4000 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\existencia_inventario.csv
desempeno_marketing: 2 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\desempeno_marketing.csv
movimientos_inventario_por_tipo: 11 filas -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\movimientos_inventario_por_tipo.csv
Resumen consolidado -> C:\Users\danie\Desktop\business_intelligence\dia_4\data\kpis\kpis_resumen.json


=== PASO 2: Generación de gráficos ===
C:\Users\danie\Desktop\business_intelligence\dia_4\graficos.py:78: UserWarning: set_ticklabels() should only be used with a fixed number
of ticks, i.e. after set_ticks() or using a FixedLocator. Otherwise, ticks may be mislabeled.
  ax.set_xticklabels(df["nombre_producto"], rotation=45, ha="right")
Gráficos generados en C:\Users\danie\Desktop\business_intelligence\dia_4\graficos



Día 4 completado: KPIs calculados y gráficos generados.
```


CTR (%) por plataforma de marketing



Distribución de ventas por método de pago







Día 5 — Documentación Final y Dashboard

Objetivo del día

Cerrar el proyecto con los entregables orientados a negocio: dashboard interactivo, informe ejecutivo, presentación para la defensa técnica y guía de preguntas frecuentes.

Qué se hizo

Dashboard interactivo (`dashboard.html`)

Dashboard con tarjetas de KPI, gráficos (Chart.js) y tablas, construido a partir de los indicadores del Día 4. Se puede abrir directamente en el navegador sin necesidad de servidor.

Dashboard automático (`actualizar_dashboard.py`)

Este es el punto clave del Día 5: el dashboard no tiene los números escritos a mano. Se diseñó para que se actualice solo cuando cambien los datos, sin editar código:

1. `calcular_kpis.py` (Día 4) genera `data/kpis/kpis_resumen.json`, un resumen consolidado de los 8 KPIs.

2. Dentro de `dashboard.html` , el bloque de datos está delimitado por dos comentarios marcadores: `// ===DATOS_INICIO===` y `// ===DATOS_FIN===` .
3. `actualizar_dashboard.py` lee `kpis_resumen.json` , renombra las columnas al formato que espera el dashboard, y reemplaza únicamente el contenido entre esos dos marcadores dentro de `dashboard.html` , dejando el resto del archivo (estilos, gráficos, estructura) intacto.

Flujo completo

1. Reemplazar los archivos crudos en `dia_2/data/raw` con los oficiales


2. Re-correr la cadena completa del pipeline:

```
python ejecutar_extraccion.py      # Día 2, parte 1
python ejecutar_limpieza.py        # Día 2, parte 2
python ejecutar_dia3.py            # Día 3 (recarga BigQuery)
python ejecutar_dia4.py            # Día 4 (recalcula KPIs + regenera
kpis_resumen.json)
```

3. Un solo comando más y el dashboard queda al día:

```
python actualizar_dashboard.py
```

Dashboard interactivo



Top clientes		
CLIENTE	SEGMENTO	TOTAL
Cliente desconocido	N/A	Q.103,374.264
Carlos Díaz	Corporativo	Q.8,934,857.99
Miguel García	Inactivo	Q.8,570,919.12
Ana García	Corporativo	Q.8,071,668.95
Miguel Pérez	Corporativo	Q.7,795,288.61
Pedro Morales	Frecuente	Q.7,780,383.36
Luis Ramírez	Nuevo	Q.7,727,561.41
Sofía Santos	Inactivo	Q.7,634,466.26
María García	Nuevo	Q.7,633,189.01
Fernanda Méndez	Corporativo	Q.7,541,195.37
Juan Pérez	Inactivo	Q.7,376,623.56
Gabriela López	Nuevo	Q.7,363,001.33
Miguel Ramírez	Corporativo	Q.7,357,685.35
Carlos Gómez	Frecuente	Q.7,289,347.11
María Gómez	Inactivo	Q.7,259,489.49
Sofía Cruz	Nuevo	Q.7,162,358.54

Existencia de inventario		
PRODUCTO	BODEGA	UNIDADES
Gaming Lenovo Modelo 603	Bodega Mixco	0
Mouse NetPro Modelo 271	Bodega Mixco	0
Impresoras NetPro Modelo 386	Sucursal Sur	0
Tinta VisionX Modelo 815	Sucursal Sur	0
Curvos HP Modelo 950	Sucursal Sur	0
Cableado SecureID Modelo 384	Sucursal Sur	0
Curvos Dell Modelo 229	Sucursal Sur	0
Toner Logitech Modelo 219	Sucursal Sur	0
Biometricos VisionX Modelo 680	Sucursal Sur	0
Mouse NetPro Modelo 540	Sucursal Sur	0
Alarmas SecureID Modelo 870	Sucursal Sur	0
All in One PrintMax Modelo 499	Sucursal Sur	0
Switches NetPro Modelo 649	Sucursal Sur	0
Toner SecureID Modelo 208	Sucursal Sur	0
Toner NetPro Modelo 113	Sucursal Sur	0
Cameras ClickIT Modelo 752	Sucursal Sur	0
Desktop VISIONX Modelo 871	Central	0

Desempeño de marketing			
PLATAFORMA	CTR	COSTO/LEAD	CONV.
Facebook	10.92%	Q.1.01	22.07%
Instagram	10.9%	Q.1.01	22.35%

Conclusiones

Validación del pipeline a escala real

El diseño de los Días 1 a 5 se construyó y probó inicialmente con una muestra de pocas filas por fuente. Al recibir el volumen oficial (255,000 ventas, 4,100 productos, 30,600 clientes), el pipeline completo — extracción, calidad, limpieza, modelado, carga y KPIs — se ejecutó de nuevo sin cambios de arquitectura, confirmando que el diseño reproducible planteado desde el Día 1 cumplió su objetivo: los mismos scripts que corrieron con 5 filas corrieron con cientos de miles.

Hallazgos de calidad que solo aparecieron con el volumen real

La muestra inicial no alcanzaba a mostrar varios problemas que sí aparecieron con los datos oficiales, y que se fueron resolviendo directamente en `clean.py`:

- `clientes.edad` con el valor "N/A" como texto en vez de nulo.
- `ventas.cantidad` y `ventas.precio_unitario` con valores no numéricos en 1,500 filas, que se descartaron y quedaron documentados con advertencia.
- `productos.precio_lista` y `costo_unitario` con valores negativos (error de captura), corregidos a valor absoluto.
- **Categorías de texto libre sin estandarizar:** `canal_venta`, `metodo_pago` y `plataforma` llegaban con decenas de variantes de la misma categoría (`Facebook`, `facebook`, `FB`, `Meta`, `FACEBOOK ADS`; `Tarjeta`, `TC`, `Visa`, `CREDITO`, etc.), resuelto con un diccionario de normalización que agrupa alias en una categoría canónica.

- **Productos con existencia en cero:** al filtrar los de menor stock, varios ya están en quiebre real, no solo en riesgo — un hallazgo que pasa directo al informe ejecutivo.

Cada uno de estos casos se resolvió sin modificar la arquitectura del pipeline: los cambios se aplicaron únicamente en las funciones de limpieza correspondientes, y el resto de las etapas (modelado, carga, KPIs, dashboard) los heredó automáticamente en la siguiente corrida.

Aprendizaje principal

El mayor riesgo del proyecto no estuvo en construir el pipeline, sino en las suposiciones que una muestra pequeña permite pasar por alto. Diseñar cada etapa para fallar de forma explícita (con `AssertionError` y `logger.warning` en vez de guardar datos incorrectos en silencio) fue lo que permitió detectar y corregir estos problemas apenas llegó el volumen real, en vez de descubrirlos después, ya con KPIs calculados sobre datos defectuosos.